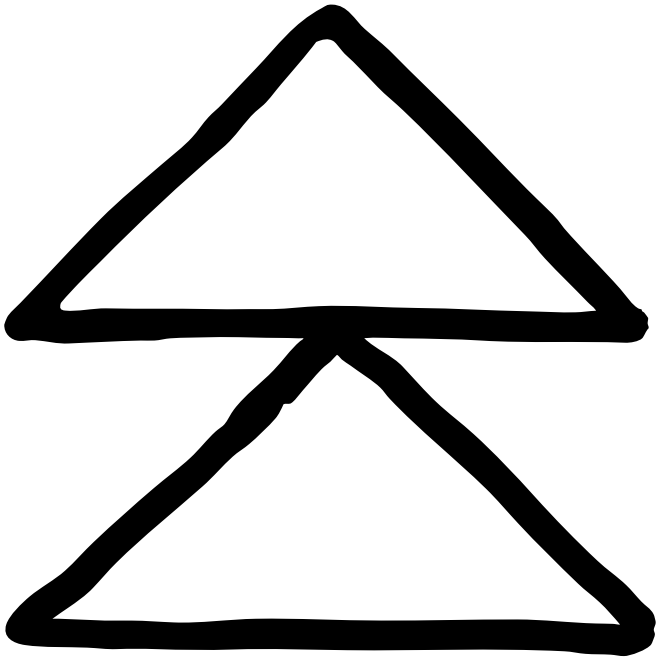

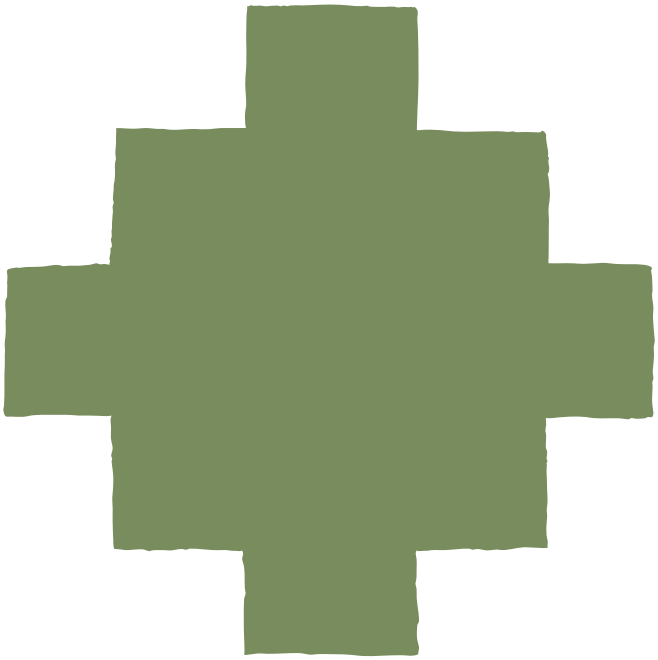

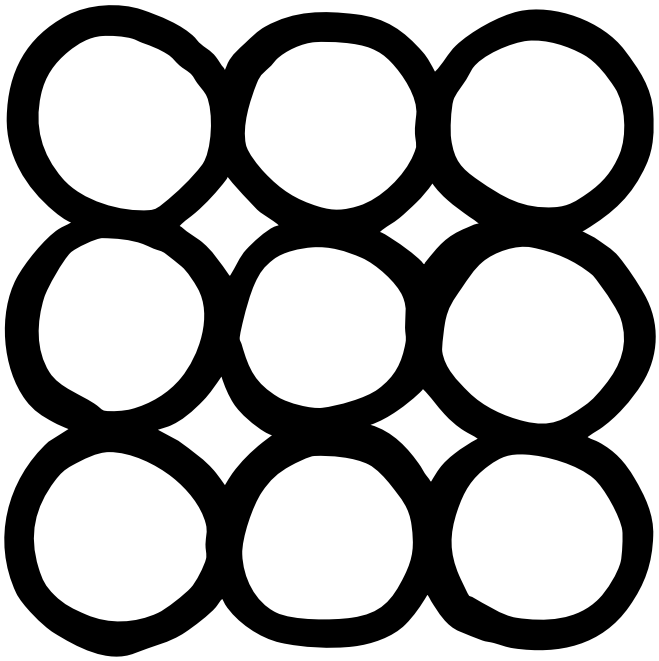

효과적인 에이전트 구축하기

게시됨2024년 12월 19일

우리는 다양한 산업 분야에서 LLM 에이전트를 구축하는 수십 개의 팀과 함께 작업해왔습니다. 일관되게, 가장 성공적인 구현들은 복잡한 프레임워크보다는 단순하고 조합 가능한 패턴을 사용했습니다.

지난 한 해 동안, 우리는 다양한 산업 분야에서 대규모 언어 모델(LLM) 에이전트를 구축하는 수십 개의 팀과 함께 작업해왔습니다. 일관되게, 가장 성공적인 구현들은 복잡한 프레임워크나 전문 라이브러리를 사용하지 않았습니다. 대신, 그들은 단순하고 조합 가능한 패턴으로 구축하고 있었습니다.

이 글에서는 고객들과 함께 작업하고 직접 에이전트를 구축하면서 배운 것들을 공유하고, 효과적인 에이전트를 구축하는 개발자들에게 실용적인 조언을 제공합니다.

에이전트란 무엇인가요?

"에이전트"는 여러 가지 방식으로 정의될 수 있습니다. 일부 고객들은 에이전트를 다양한 도구를 사용하여 복잡한 작업을 수행하면서 장기간에 걸쳐 독립적으로 작동하는 완전히 자율적인 시스템으로 정의합니다. 다른 고객들은 미리 정의된 워크플로우를 따르는 보다 규정적인 구현을 설명하기 위해 이 용어를 사용합니다. Anthropic에서는 이러한 모든 변형을**에이전틱 시스템**으로 분류하지만,**워크플로우**와**에이전트**:

- **워크플로우**는 LLM과 도구들이 미리 정의된 코드 경로를 통해 조율되는 시스템입니다.
- **에이전트**는 반면에 LLM이 자신의 프로세스와 도구 사용을 동적으로 지시하며, 작업을 수행하는 방법에 대한 제어권을 유지하는 시스템입니다.

아래에서는 두 가지 유형의 에이전트 시스템을 자세히 살펴보겠습니다. 부록 1("실제 에이전트")에서는 고객들이 이러한 종류의 시스템을 사용하여 특별한 가치를 발견한 두 가지 영역을 설명합니다.

에이전트를 언제 사용해야 하고 언제 사용하지 말아야 하는가

LLM으로 애플리케이션을 구축할 때는 가능한 한 가장 간단한 솔루션을 찾고, 필요할 때만 복잡성을 증가시키는 것을 권장합니다. 이는 에이전트 시스템을 전혀 구축하지 않는 것을 의미할 수도 있습니다. 에이전트 시스템은 종종 더 나은 작업 성능을 위해 지연 시간과 비용을 희생하므로, 이러한 트레이드오프가 언제 합리적인지 고려해야 합니다.

복잡성이 더 필요한 경우, 워크플로는 잘 정의된 작업에 대해 예측 가능성과 일관성을 제공하는 반면, 에이전트는 대규모에서 유연성과 모델 기반 의사결정이 필요할 때 더 나은 선택입니다. 하지만 많은 애플리케이션에서는 검색과 컨텍스트 내 예시를 통해 단일 LLM 호출을 최적화하는 것만으로도 충분합니다.

프레임워크를 언제, 어떻게 사용할지

에이전트 시스템을 더 쉽게 구현할 수 있게 해주는 많은 프레임워크들이 있습니다:

- LangGraph from LangChain;
- Amazon Bedrock의AI 에이전트 프레임워크;
- Rivet, 드래그 앤 드롭 GUI LLM 워크플로우 빌더; 그리고
- Vellum, 복잡한 워크플로우를 구축하고 테스트하기 위한 또 다른 GUI 도구입니다.

이러한 프레임워크들은 LLM 호출, 도구 정의 및 파싱, 호출 연결과 같은 표준적인 저수준 작업을 단순화하여 시작하기 쉽게 만들어줍니다. 하지만 종종 추가적인 추상화 계층을 만들어 기본 프롬프트와 응답을 모호하게 하여 디버깅을 어렵게 만들 수 있습니다. 또한 더 간단한 설정으로도 충분할 때 복잡성을 추가하고 싶은 유혹을 불러일으킬 수도 있습니다.

개발자들이 LLM API를 직접 사용하는 것부터 시작하기를 권장합니다. 많은 패턴들이 몇 줄의 코드로 구현될 수 있습니다. 프레임워크를 사용한다면, 기본 코드를 이해하고 있는지 확인하세요. 내부 작동 방식에 대한 잘못된 가정은 고객 오류의 일반적인 원인입니다.

샘플 구현을 위해 저희 **쿡북**을 참조하세요.

구성 요소, 워크플로우, 그리고 에이전트

이 섹션에서는 프로덕션 환경에서 확인한 에이전틱 시스템의 일반적인 패턴들을 살펴보겠습니다. 기본 구성 요소인 증강된 LLM부터 시작하여, 단순한 구성적 워크플로우에서 자율 에이전트까지 점진적으로 복잡성을 높여가며 다루겠습니다.

구성 요소: 증강된 LLM

에이전틱 시스템의 기본 구성 요소는 검색, 도구, 메모리와 같은 증강 기능으로 향상된 LLM입니다. 현재의 모델들은 이러한 기능들을 능동적으로 사용할 수 있습니다—자체적으로 검색 쿼리를 생성하고, 적절한 도구를 선택하며, 어떤 정보를 보관할지 결정합니다.

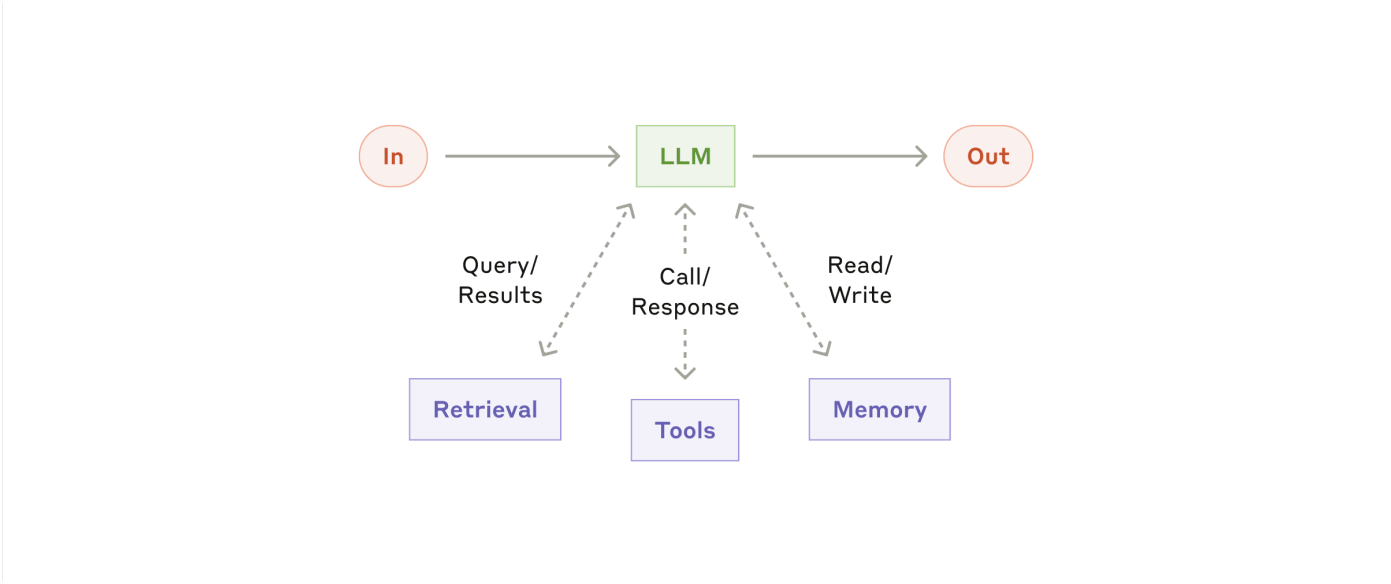

증강된 LLM

구현 시 두 가지 핵심 측면에 집중할 것을 권장합니다: 이러한 기능들을 특정 사용 사례에 맞게 조정하고, LLM에 쉽고 잘 문서화된 인터페이스를 제공하는 것입니다. 이러한 확장 기능을 구현하는 방법은 여러 가지가 있지만, 한 가지 접근법은 최근 출시된 **모델 컨텍스트 프로토콜**을 통하는 것으로, 이를 통해 개발자들은 간단한 **클라이언트 구현으로 성장하는 서드파티 도구 생태계와 통합할 수 있습니다**.

이 게시물의 나머지 부분에서는 각 LLM 호출이 이러한 확장된 기능에 액세스할 수 있다고 가정하겠습니다.

워크플로우: 프롬프트 체이닝

프롬프트 체이닝은 작업을 일련의 단계로 분해하여, 각 LLM 호출이 이전 단계의 출력을 처리하도록 합니다. 중간 단계에서 프로그래밍적 검사(아래 다이어그램의 "게이트" 참조)를 추가하여 프로세스가 여전히 올바른 방향으로 진행되고 있는지 확인할 수 있습니다.

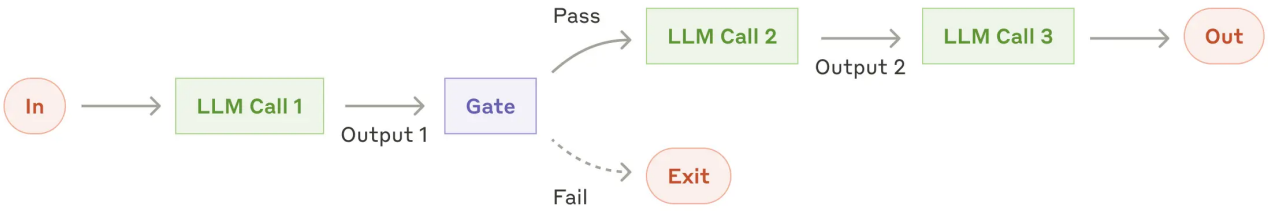

프롬프트 체이닝 워크플로우

이 워크플로우를 사용하는 경우:이 워크플로우는 작업을 고정된 하위 작업으로 쉽고 깔끔하게 분해할 수 있는 상황에 이상적입니다. 주요 목표는 각 LLM 호출을 더 쉬운 작업으로 만들어 지연 시간을 정확도와 교환하는 것입니다.

프롬프트 체이닝이 유용한 예시:

- 마케팅 카피를 생성한 다음, 다른 언어로 번역하기.
- 문서의 개요를 작성하고, 개요가 특정 기준을 충족하는지 확인한 다음, 개요를 바탕으로 문서를 작성하는 것입니다.

워크플로우: 라우팅

라우팅은 입력을 분류하고 전문화된 후속 작업으로 안내합니다. 이 워크플로우는 관심사의 분리를 가능하게 하고, 더 전문화된 프롬프트를 구축할 수 있게 합니다. 이 워크플로우 없이는 한 종류의 입력에 최적화하는 것이 다른 입력들의 성능을 저해할 수 있습니다.

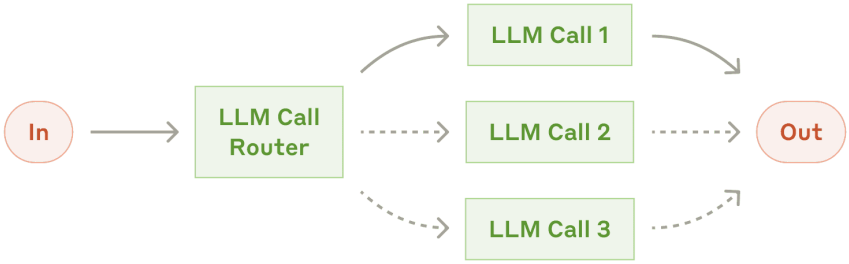

라우팅 워크플로우

이 워크플로우를 사용하는 경우:라우팅은 별도로 처리하는 것이 더 나은 뚜렷한 범주가 있고, LLM이나 더 전통적인 분류 모델/알고리즘에 의해 분류가 정확하게 처리될 수 있는 복잡한 작업에서 잘 작동합니다.

라우팅이 유용한 예시:

- 다양한 유형의 고객 서비스 문의(일반 질문, 환불 요청, 기술 지원)를 서로 다른 하위 프로세스, 프롬프트, 도구로 분류하는 것.
- 쉽고 일반적인 질문은 Claude Haiku 4.5와 같은 소형의 비용 효율적인 모델로, 어렵고 특이한 질문은 Claude Sonnet 4.5와 같은 더 강력한 모델로 라우팅하여 최적의 성능을 위해 최적화하는 것.

워크플로우: 병렬화

LLM은 때때로 작업을 동시에 수행하고 그 결과를 프로그래밍 방식으로 집계할 수 있습니다. 이러한 워크플로우인 병렬화는 두 가지 주요 변형으로 나타납니다:

- **섹셔닝**: 작업을 병렬로 실행되는 독립적인 하위 작업으로 나누는 것.
- **투표:** 다양한 결과를 얻기 위해 동일한 작업을 여러 번 실행하는 것.

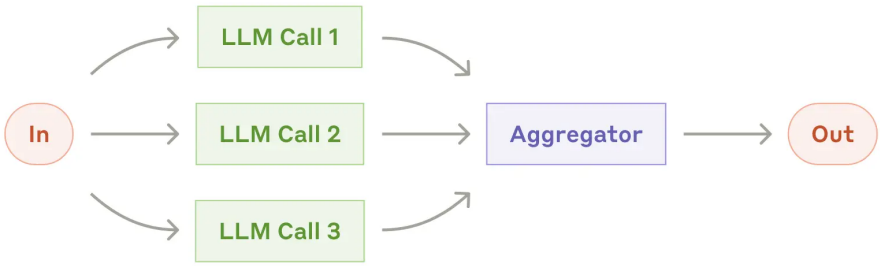

병렬화 워크플로우

이 워크플로우를 사용하는 경우:병렬화는 분할된 하위 작업을 속도를 위해 병렬 처리할 수 있거나, 더 높은 신뢰도의 결과를 위해 여러 관점이나 시도가 필요한 경우에 효과적입니다. 여러 고려사항이 있는 복잡한 작업의 경우, LLM은 일반적으로 각 고려사항을 별도의 LLM 호출로 처리할 때 더 나은 성능을 보이며, 이를 통해 각 특정 측면에 집중된 주의를 기울일 수 있습니다.

병렬화가 유용한 예시:

- **섹셔닝**:
    - 한 모델 인스턴스는 사용자 쿼리를 처리하고 다른 모델 인스턴스는 부적절한 콘텐츠나 요청을 검열하는 가드레일을 구현하는 것입니다. 이는 동일한 LLM 호출이 가드레일과 핵심 응답을 모두 처리하는 것보다 더 나은 성능을 보이는 경향이 있습니다.
    - LLM 성능을 평가하기 위한 자동화된 평가를 구현하는 것으로, 각 LLM 호출이 주어진 프롬프트에 대한 모델 성능의 서로 다른 측면을 평가합니다.
- **투표**:
    - 여러 개의 서로 다른 프롬프트가 코드를 검토하고 문제를 발견하면 플래그를 표시하는 방식으로 코드의 취약점을 검토하는 것.
    - 주어진 콘텐츠가 부적절한지 평가하는 것으로, 여러 프롬프트가 서로 다른 측면을 평가하거나 거짓 양성과 거짓 음성의 균형을 맞추기 위해 서로 다른 투표 임계값을 요구하는 방식.

워크플로우: 오케스트레이터-워커

오케스트레이터-워커 워크플로우에서는 중앙 LLM이 동적으로 작업을 분해하고, 이를 워커 LLM들에게 위임하며, 그들의 결과를 종합합니다.

오케스트레이터-워커 워크플로우

이 워크플로우를 사용하는 경우:이 워크플로우는 필요한 하위 작업을 예측할 수 없는 복잡한 작업에 적합합니다(예를 들어, 코딩에서 변경해야 할 파일의 수와 각 파일에서 변경의 성격은 작업에 따라 달라질 가능성이 높습니다). 지형학적으로는 유사하지만, 병렬화와의 주요 차이점은 유연성입니다. 하위 작업이 미리 정의되지 않고, 특정 입력에 기반하여 오케스트레이터가 결정합니다.

오케스트레이터-워커가 유용한 예시:

- 매번 여러 파일에 복잡한 변경을 가하는 코딩 제품.
- 여러 소스에서 관련 가능성이 있는 정보를 수집하고 분석하는 검색 작업.

워크플로우: 평가자-최적화자

평가자-최적화자 워크플로우에서는 하나의 LLM 호출이 응답을 생성하고 다른 하나가 루프에서 평가와 피드백을 제공합니다.

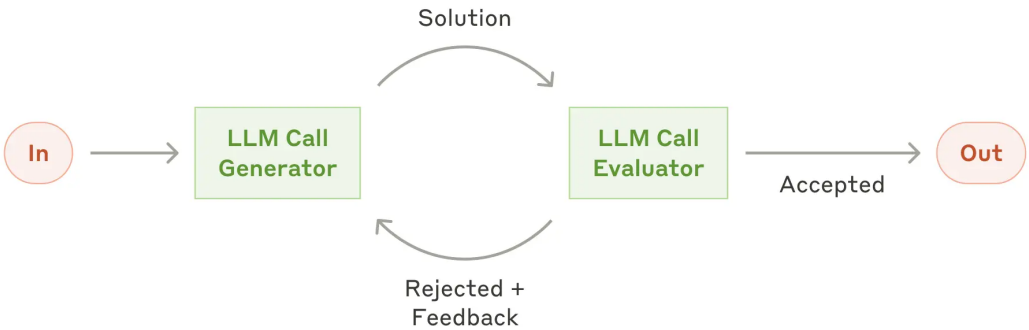

평가자-최적화자 워크플로

이 워크플로우를 사용하는 경우:이 워크플로는 명확한 평가 기준이 있고, 반복적인 개선이 측정 가능한 가치를 제공할 때 특히 효과적입니다. 적합성을 나타내는 두 가지 신호는 첫째, 인간이 피드백을 명확히 표현할 때 LLM 응답이 명백히 개선될 수 있다는 것이고, 둘째, LLM이 그러한 피드백을 제공할 수 있다는 것입니다. 이는 인간 작가가 완성된 문서를 작성할 때 거치는 반복적인 글쓰기 과정과 유사합니다.

평가자-최적화자가 유용한 예시들:

- 번역자 LLM이 처음에는 포착하지 못할 수 있는 뉘앙스가 있지만, 평가자 LLM이 유용한 비평을 제공할 수 있는 문학 번역.
- 포괄적인 정보 수집을 위해 여러 차례의 검색과 분석이 필요한 복잡한 검색 작업으로, 평가자가 추가 검색이 필요한지 여부를 결정합니다.

에이전트

에이전트는 LLM이 복잡한 입력 이해, 추론과 계획 수행, 도구의 안정적 사용, 오류 복구 등 핵심 역량에서 성숙해짐에 따라 프로덕션 환경에서 등장하고 있습니다. 에이전트는 인간 사용자의 명령이나 대화형 토론으로 작업을 시작합니다. 작업이 명확해지면, 에이전트는 독립적으로 계획하고 운영하며, 추가 정보나 판단이 필요할 때 인간에게 돌아갈 수 있습니다. 실행 중에는 에이전트가 각 단계에서 환경으로부터 "실제 상황"(도구 호출 결과나 코드 실행 등)을 파악하여 진행 상황을 평가하는 것이 중요합니다. 에이전트는 체크포인트에서나 장애물에 부딪혔을 때 인간의 피드백을 위해 일시 정지할 수 있습니다. 작업은 완료 시 종료되는 경우가 많지만, 제어를 유지하기 위해 중단 조건(최대 반복 횟수 등)을 포함하는 것도 일반적입니다.

에이전트는 복잡한 작업을 처리할 수 있지만, 구현은 종종 간단합니다. 일반적으로 환경 피드백을 기반으로 루프에서 도구를 사용하는 LLM일 뿐입니다. 따라서 도구 세트와 그 문서를 명확하고 신중하게 설계하는 것이 중요합니다. 부록 2("도구 프롬프트 엔지니어링")에서 도구 개발 모범 사례를 자세히 설명합니다.

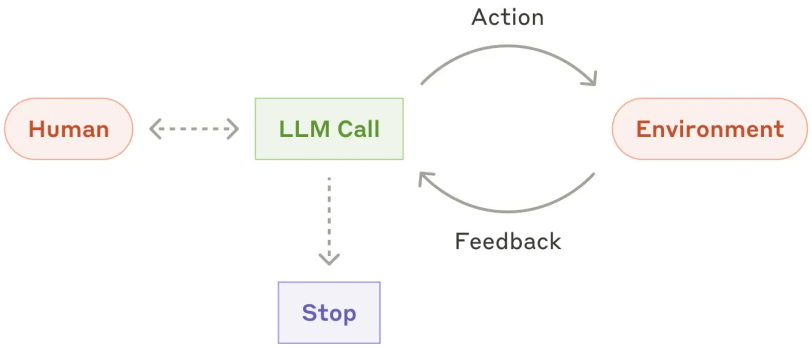

자율 에이전트

에이전트를 사용해야 하는 경우:에이전트는 필요한 단계 수를 예측하기 어렵거나 불가능하고, 고정된 경로를 하드코딩할 수 없는 개방형 문제에 사용할 수 있습니다. LLM은 잠재적으로 많은 턴 동안 작동할 것이며, 그 의사결정에 어느 정도 신뢰를 가져야 합니다. 에이전트의 자율성은 신뢰할 수 있는 환경에서 작업을 확장하는 데 이상적입니다.

에이전트의 자율적 특성은 더 높은 비용과 오류가 누적될 가능성을 의미합니다. 샌드박스 환경에서의 광범위한 테스트와 적절한 가드레일을 권장합니다.

에이전트가 유용한 예시들:

다음 예시들은 저희가 직접 구현한 것들입니다:

- 해결을 위한 코딩 에이전트SWE-bench 작업, 작업 설명을 기반으로 많은 파일을 편집하는 작업;
- 우리의 "컴퓨터 사용" 참조 구현, Claude가 컴퓨터를 사용하여 작업을 수행하는 곳.

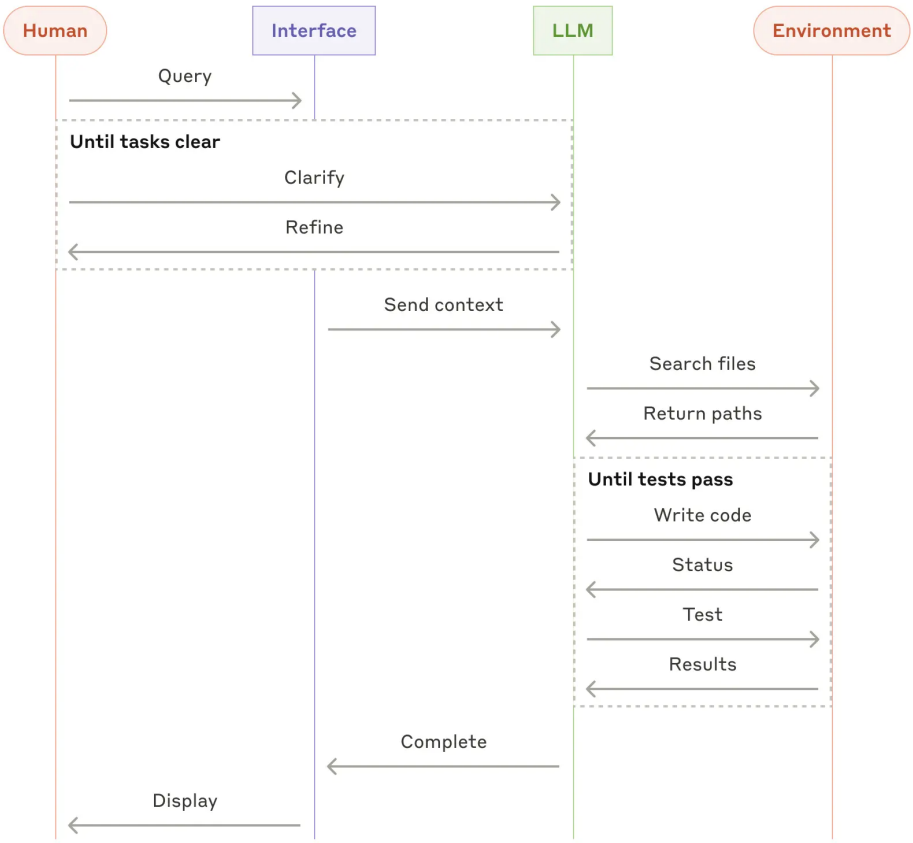

코딩 에이전트의 고수준 플로우

이러한 패턴들의 결합과 커스터마이징

이러한 구성 요소들은 규정적이지 않습니다. 개발자들이 다양한 사용 사례에 맞게 형태를 만들고 결합할 수 있는 일반적인 패턴들입니다. 다른 LLM 기능들과 마찬가지로 성공의 핵심은 성능을 측정하고 구현을 반복하는 것입니다. 다시 강조하자면: 복잡성을 추가하는 것은 *오직* 결과가 명백히 개선될 때만 고려해야 합니다.

요약

LLM 분야에서의 성공은 가장 정교한 시스템을 구축하는 것이 아닙니다. 당신의 필요에 *적합한* 시스템을 구축하는 것입니다. 간단한 프롬프트로 시작하여 포괄적인 평가를 통해 최적화하고, 더 간단한 솔루션이 부족할 때만 다단계 에이전트 시스템을 추가하세요.

에이전트를 구현할 때, 우리는 세 가지 핵심 원칙을 따르려고 합니다:

1. 에이전트 설계에서**단순함을**유지하세요.
2. 우선순위를 두세요**투명성**에이전트의 계획 단계를 명시적으로 보여줌으로써.
3. 철저한 도구를 통해 에이전트-컴퓨터 인터페이스(ACI)를 신중하게 설계하세요**문서화 및 테스트**.

프레임워크는 빠른 시작에 도움이 될 수 있지만, 프로덕션으로 이동할 때는 추상화 레이어를 줄이고 기본 컴포넌트로 구축하는 것을 주저하지 마세요. 이러한 원칙을 따르면 강력할 뿐만 아니라 신뢰할 수 있고, 유지보수가 가능하며, 사용자들이 신뢰할 수 있는 에이전트를 만들 수 있습니다.

감사의 말

Erik Schluntz와 Barry Zhang이 작성했습니다. 이 작업은 Anthropic에서 에이전트를 구축한 우리의 경험과 고객들이 공유해 준 소중한 통찰력을 바탕으로 하며, 이에 대해 깊이 감사드립니다.

부록 1: 실무에서의 에이전트

고객과의 협업을 통해 위에서 논의한 패턴들의 실용적 가치를 보여주는 AI 에이전트의 두 가지 특히 유망한 응용 분야를 발견했습니다. 두 응용 분야 모두 대화와 행동이 모두 필요하고, 명확한 성공 기준이 있으며, 피드백 루프를 가능하게 하고, 의미 있는 인간 감독을 통합하는 작업에서 에이전트가 가장 큰 가치를 추가하는 방법을 보여줍니다.

A. 고객 지원

고객 지원은 친숙한 챗봇 인터페이스와 도구 통합을 통한 향상된 기능을 결합합니다. 이는 보다 개방적인 에이전트에 자연스럽게 적합한데, 그 이유는 다음과 같습니다:

- 지원 상호작용은 외부 정보와 작업에 대한 접근이 필요하면서도 자연스럽게 대화 흐름을 따릅니다;
- 고객 데이터, 주문 내역, 지식 베이스 문서를 가져오는 도구들을 통합할 수 있습니다;
- 환불 처리나 티켓 업데이트와 같은 작업들은 프로그래밍 방식으로 처리할 수 있습니다; 그리고
- 성공은 사용자 정의 해결책을 통해 명확하게 측정할 수 있습니다.

여러 회사들이 성공적인 해결에 대해서만 요금을 부과하는 사용량 기반 가격 모델을 통해 이 접근 방식의 실행 가능성을 입증했으며, 이는 자사 에이전트의 효과에 대한 확신을 보여줍니다.

B. 코딩 에이전트

소프트웨어 개발 분야는 LLM 기능에 대해 놀라운 잠재력을 보여주었으며, 코드 완성에서 자율적 문제 해결까지 기능이 발전하고 있습니다. 에이전트가 특히 효과적인 이유는 다음과 같습니다:

- 코드 솔루션은 자동화된 테스트를 통해 검증 가능합니다;
- 에이전트는 테스트 결과를 피드백으로 활용하여 솔루션을 반복 개선할 수 있습니다;
- 문제 공간이 잘 정의되고 구조화되어 있습니다; 그리고
- 출력 품질은 객관적으로 측정할 수 있습니다.

우리 자체 구현에서 에이전트들은 이제 풀 리퀘스트 설명만으로도 실제 GitHub 이슈들을 해결할 수 있습니다.SWE-bench Verified벤치마크에서 말입니다. 하지만 자동화된 테스팅이 기능성을 검증하는 데 도움이 되는 반면, 솔루션이 더 광범위한 시스템 요구사항과 일치하는지 확인하기 위해서는 인간의 검토가 여전히 중요합니다.

부록 2: 도구 프롬프트 엔지니어링

어떤 에이전트 시스템을 구축하든, 도구는 에이전트의 중요한 부분이 될 것입니다.도구Claude가 API에서 정확한 구조와 정의를 지정하여 외부 서비스 및 API와 상호작용할 수 있도록 합니다. Claude가 응답할 때, 다음을 포함합니다도구 사용 블록API 응답에서 도구를 호출할 계획이 있는 경우에 포함됩니다. 도구 정의와 사양은 전체 프롬프트만큼이나 프롬프트 엔지니어링에 주의를 기울여야 합니다. 이 간단한 부록에서는 도구를 프롬프트 엔지니어링하는 방법을 설명합니다.

동일한 작업을 지정하는 방법은 종종 여러 가지가 있습니다. 예를 들어, diff를 작성하거나 전체 파일을 다시 작성하여 파일 편집을 지정할 수 있습니다. 구조화된 출력의 경우, 마크다운 내부나 JSON 내부에 코드를 반환할 수 있습니다. 소프트웨어 엔지니어링에서 이러한 차이점들은 표면적인 것이며 하나에서 다른 것으로 손실 없이 변환할 수 있습니다. 그러나 일부 형식은 LLM이 작성하기에 다른 형식보다 훨씬 더 어렵습니다. diff를 작성하려면 새 코드가 작성되기 전에 청크 헤더에서 몇 줄이 변경되는지 알아야 합니다. (마크다운과 비교하여) JSON 내부에 코드를 작성하려면 개행과 따옴표의 추가 이스케이프 처리가 필요합니다.

도구 형식을 결정하는 데 대한 우리의 제안은 다음과 같습니다:

- 모델이 막다른 길에 빠지기 전에 "생각할" 수 있는 충분한 토큰을 제공하세요.
- 형식을 모델이 인터넷 텍스트에서 자연스럽게 접한 것과 유사하게 유지하세요.
- 수천 줄의 코드를 정확히 세어야 하거나 작성하는 코드를 문자열 이스케이프 처리해야 하는 것과 같은 형식적 "오버헤드"가 없도록 하세요.

클릭하여 재시도 *클릭하여 재시도* 클릭하여 재시도

- 모델의 입장에서 생각해보세요. 설명과 매개변수를 바탕으로 이 도구를 어떻게 사용해야 하는지 명확한가요, 아니면 신중하게 생각해야 하나요? 만약 그렇다면, 모델에게도 마찬가지일 것입니다. 좋은 도구 정의에는 사용 예시, 예외 상황, 입력 형식 요구사항, 그리고 다른 도구들과의 명확한 경계가 포함되는 경우가 많습니다.
- 매개변수 이름이나 설명을 어떻게 변경하여 더 명확하게 만들 수 있을까요? 이를 팀의 주니어 개발자를 위한 훌륭한 독스트링을 작성하는 것으로 생각해보세요. 이는 많은 유사한 도구를 사용할 때 특히 중요합니다.

- 모델이 도구를 어떻게 사용하는지 테스트하세요: 워크벤치에서 많은 예시 입력을 실행하여 모델이 어떤 실수를 하는지 확인하고 반복 개선하세요.
- 포카요케도구를 개선하세요. 실수하기 어렵도록 인수를 변경하세요.

우리가 SWE-bench용 에이전트를 구축하는 동안, 실제로 전체 프롬프트보다 도구를 최적화하는 데 더 많은 시간을 보냈습니다. 예를 들어, 에이전트가 루트 디렉토리에서 벗어난 후 상대 파일 경로를 사용하는 도구에서 모델이 실수를 한다는 것을 발견했습니다. 이를 해결하기 위해 항상 절대 파일 경로를 요구하도록 도구를 변경했고, 모델이 이 방법을 완벽하게 사용한다는 것을 발견했습니다.

Building effective agents

Published Dec 19, 2024

We've worked with dozens of teams building LLM agents across industries. Consistently, the most successful implementations use simple, composable patterns rather than complex frameworks.

Over the past year, we've worked with dozens of teams building large language model (LLM) agents across industries. Consistently, the most successful implementations weren't using complex frameworks or specialized libraries. Instead, they were building with simple, composable patterns.

In this post, we share what we've learned from working with our customers and building agents ourselves, and give practical advice for developers on building effective agents.

What are agents?

"Agent" can be defined in several ways. Some customers define agents as fully autonomous systems that operate independently over extended periods, using various tools to accomplish complex tasks. Others use the term to describe more prescriptive implementations that follow predefined workflows. At Anthropic, we categorize all these variations as **agentic systems**, but draw an important architectural distinction between **workflows** and **agents**:

- **Workflows** are systems where LLMs and tools are orchestrated through predefined code paths.
- **Agents**, on the other hand, are systems where LLMs dynamically direct their own processes and tool usage, maintaining control over how they accomplish tasks.

Below, we will explore both types of agentic systems in detail. In Appendix 1 ("Agents in Practice"), we describe two domains where customers have found particular value in using these kinds of systems.

When (and when not) to use agents

When building applications with LLMs, we recommend finding the simplest solution possible, and only increasing complexity when needed. This might mean not building agentic systems at all. Agentic systems often trade latency and cost for better task performance, and you should consider when this tradeoff makes sense.

When more complexity is warranted, workflows offer predictability and consistency for well-defined tasks, whereas agents are the better option when flexibility and model-driven decision-making are needed at scale. For many applications, however, optimizing single LLM calls with retrieval and in-context examples is usually enough.

When and how to use frameworks

There are many frameworks that make agentic systems easier to implement, including:

- LangGraph from LangChain;
- Amazon Bedrock's AI Agent framework;
- Rivet, a drag and drop GUI LLM workflow builder; and
- Vellum, another GUI tool for building and testing complex workflows.

These frameworks make it easy to get started by simplifying standard low-level tasks like calling LLMs, defining and parsing tools, and chaining calls together. However, they often create extra layers of abstraction that can obscure the underlying prompts and responses, making them harder to debug. They can also make it tempting to add complexity when a simpler setup would suffice.

We suggest that developers start by using LLM APIs directly: many patterns can be implemented in a few lines of code. If you do use a framework, ensure you understand the underlying code. Incorrect assumptions about what's under the hood are a common source of customer error.

See our cookbook for some sample implementations.

Building blocks, workflows, and agents

In this section, we'll explore the common patterns for agentic systems we've seen in production. We'll start with our foundational building block—the augmented LLM—and progressively increase complexity, from simple compositional workflows to autonomous agents.

Building block: The augmented LLM

The basic building block of agentic systems is an LLM enhanced with augmentations such as retrieval, tools, and memory. Our current models can actively use these capabilities—generating their own search queries, selecting appropriate tools, and determining what information to retain.

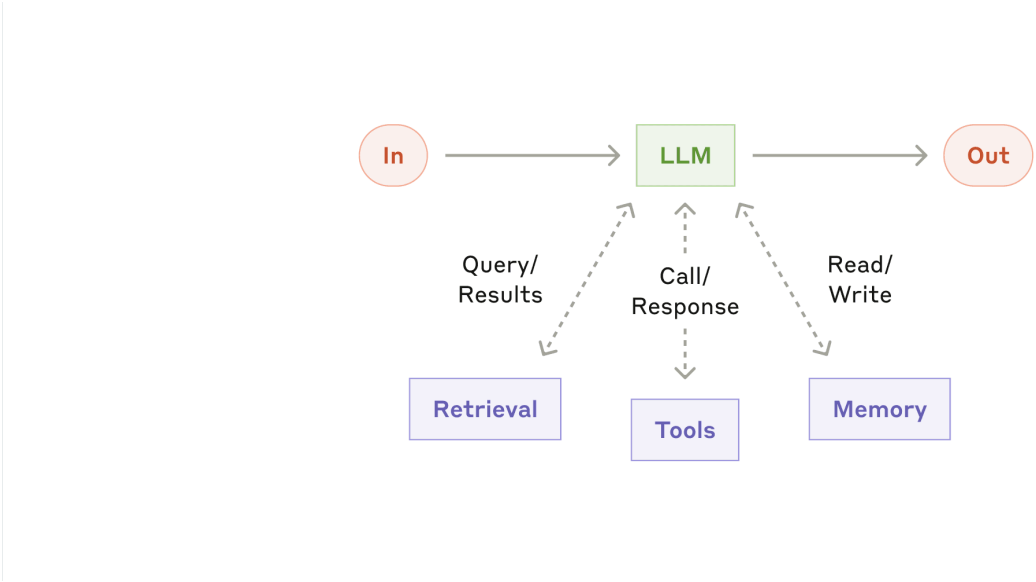

The augmented LLM

We recommend focusing on two key aspects of the implementation: tailoring these capabilities to your specific use case and ensuring they provide an easy, well-documented interface for your LLM. While there are many ways to implement these augmentations, one approach is through our recently released Model Context Protocol, which allows developers to integrate with a growing ecosystem of third-party tools with a simple client implementation.

For the remainder of this post, we'll assume each LLM call has access to these augmented capabilities.

Workflow: Prompt chaining

Prompt chaining decomposes a task into a sequence of steps, where each LLM call processes the output of the previous one. You can add programmatic checks (see "gate" in the diagram below) on any intermediate steps to ensure that the process is still on track.

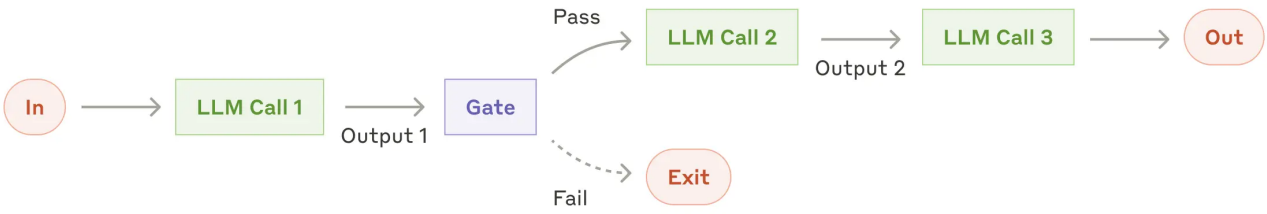

The prompt chaining workflow

When to use this workflow: This workflow is ideal for situations where the task can be easily and cleanly decomposed into fixed subtasks. The main goal is to trade off latency for higher accuracy, by making each LLM call an easier task.

Examples where prompt chaining is useful:

- Generating Marketing copy, then translating it into a different language.
- Writing an outline of a document, checking that the outline meets certain criteria, then writing the document based on the outline.

Workflow: Routing

Routing classifies an input and directs it to a specialized followup task. This workflow allows for separation of concerns, and building more specialized prompts. Without this workflow, optimizing for one kind of input can hurt performance on other inputs.

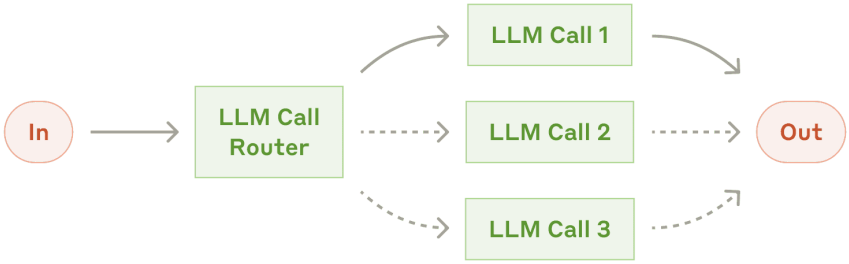

The routing workflow

When to use this workflow: Routing works well for complex tasks where there are distinct categories that are better handled separately, and where classification can be handled accurately, either by an LLM or a more traditional classification model/algorithm.

Examples where routing is useful:

- Directing different types of customer service queries (general questions, refund requests, technical support) into different downstream processes, prompts, and tools.
- Routing easy/common questions to smaller, cost-efficient models like Claude Haiku 4.5 and hard/unusual questions to more capable models like Claude Sonnet 4.5 to optimize for best performance.

Workflow: Parallelization

LLMs can sometimes work simultaneously on a task and have their outputs aggregated programmatically. This workflow, parallelization, manifests in two key variations:

- **Sectioning**: Breaking a task into independent subtasks run in parallel.
- **Voting:** Running the same task multiple times to get diverse outputs.

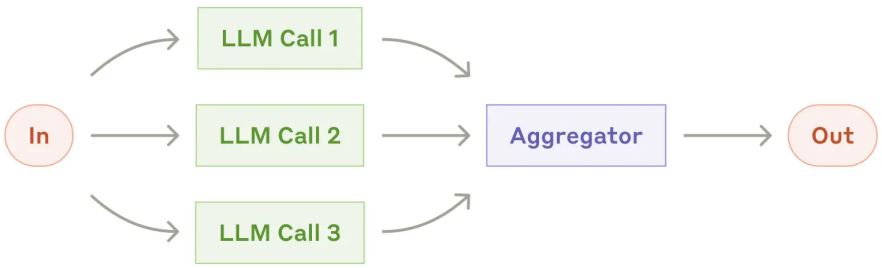

The parallelization workflow

When to use this workflow: Parallelization is effective when the divided subtasks can be parallelized for speed, or when multiple perspectives or attempts are needed for higher confidence results. For complex tasks with multiple considerations, LLMs generally perform better when each consideration is handled by a separate LLM call, allowing focused attention on each specific aspect.

Examples where parallelization is useful:

- **Sectioning**:
    - Implementing guardrails where one model instance processes user queries while another

screens them for inappropriate content or requests. This tends to perform better than having the same LLM call handle both guardrails and the core response.

    - Automating evals for evaluating LLM performance, where each LLM call evaluates a different aspect of the model's performance on a given prompt.

- **Voting**:
    - Reviewing a piece of code for vulnerabilities, where several different prompts review and flag the code if they find a problem.
    - Evaluating whether a given piece of content is inappropriate, with multiple prompts evaluating different aspects or requiring different vote thresholds to balance false positives and negatives.

Workflow: Orchestrator-workers

In the orchestrator-workers workflow, a central LLM dynamically breaks down tasks, delegates them to worker LLMs, and synthesizes their results.

The orchestrator-workers workflow

When to use this workflow: This workflow is well-suited for complex tasks where you can't predict the subtasks needed (in coding, for example, the number of files that need to be changed and the nature of the change in each file likely depend on the task). Whereas it's topographically similar, the key difference from parallelization is its flexibility—subtasks aren't pre-defined, but determined by the orchestrator based on the specific input.

Example where orchestrator-workers is useful:

- Coding products that make complex changes to multiple files each time.
- Search tasks that involve gathering and analyzing information from multiple sources for possible relevant information.

Workflow: Evaluator-optimizer

In the evaluator-optimizer workflow, one LLM call generates a response while another provides evaluation and feedback in a loop.

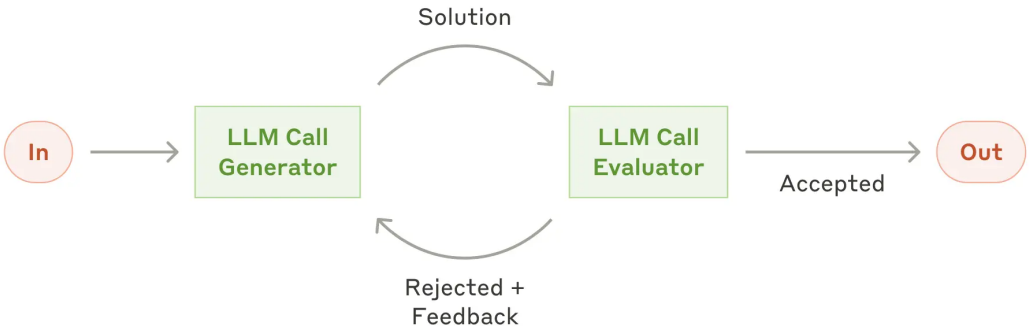

The evaluator-optimizer workflow

When to use this workflow: This workflow is particularly effective when we have clear evaluation criteria, and when iterative refinement provides measurable value. The two signs of good fit are, first, that LLM responses can be demonstrably improved when a human articulates their feedback; and second, that the LLM can provide such feedback. This is analogous to the iterative writing process a human writer might go through when producing a polished document.

Examples where evaluator-optimizer is useful:

- Literary translation where there are nuances that the translator LLM might not capture initially, but where an evaluator LLM can provide useful critiques.
- Complex search tasks that require multiple rounds of searching and analysis to gather comprehensive information, where the evaluator decides whether further searches are warranted.

Agents

Agents are emerging in production as LLMs mature in key capabilities—understanding complex inputs, engaging in reasoning and planning, using tools reliably, and recovering from errors. Agents begin their work with either a command from, or interactive discussion with, the human user. Once the task is clear, agents plan and operate independently, potentially returning to the human for further information or judgement. During execution, it's crucial for the agents to gain “ground truth” from the environment at each step (such as tool call results or code execution) to assess its progress. Agents can then pause for human feedback at checkpoints or when encountering blockers. The task often terminates upon completion, but it’s also common to include stopping conditions (such as a maximum number of iterations) to maintain control.

Agents can handle sophisticated tasks, but their implementation is often straightforward. They are typically just LLMs using tools based on environmental feedback in a loop. It is therefore crucial to design toolsets and their documentation clearly and thoughtfully. We expand on best practices for tool development in Appendix 2 ("Prompt Engineering your Tools").

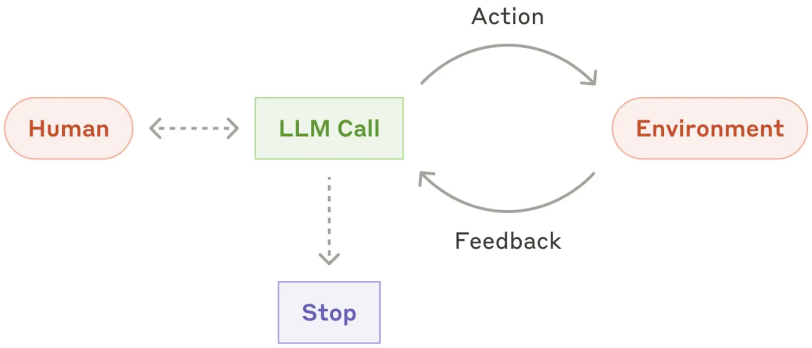

Autonomous agent

When to use agents: Agents can be used for open-ended problems where it's difficult or impossible to predict the required number of steps, and where you can't hardcode a fixed path. The LLM will potentially operate for many turns, and you must have some level of trust in its decision-making. Agents' autonomy makes them ideal for scaling tasks in trusted environments.

The autonomous nature of agents means higher costs, and the potential for compounding errors. We recommend extensive testing in sandboxed environments, along with the appropriate guardrails.

Examples where agents are useful:

The following examples are from our own implementations:

- A coding Agent to resolve SWE-bench tasks, which involve edits to many files based on a task description;
- Our "computer use" reference implementation, where Claude uses a computer to accomplish tasks.

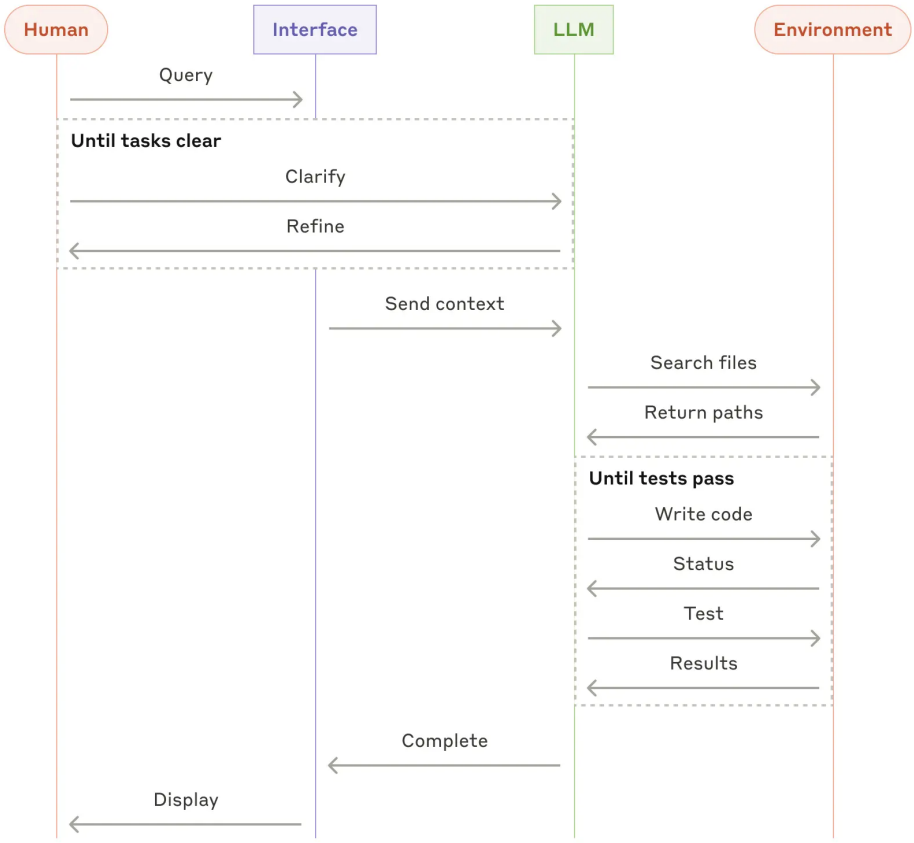

High-level flow of a coding agent

Combining and customizing these patterns

These building blocks aren't prescriptive. They're common patterns that developers can shape and combine to fit different use cases. The key to success, as with any LLM features, is measuring performance and iterating on implementations. To repeat: you should consider adding complexity *only* when it demonstrably improves outcomes.

Summary

Success in the LLM space isn't about building the most sophisticated system. It's about building the *right* system for your needs. Start with simple prompts, optimize them with comprehensive evaluation, and add multi-step agentic systems only when simpler solutions fall short.

When implementing agents, we try to follow three core principles:

1. Maintain **simplicity** in your agent's design.
2. Prioritize **transparency** by explicitly showing the agent's planning steps.

3. Carefully craft your agent-computer interface (ACI) through thorough tool **documentation and testing**.

Frameworks can help you get started quickly, but don't hesitate to reduce abstraction layers and build with basic components as you move to production. By following these principles, you can create agents that are not only powerful but also reliable, maintainable, and trusted by their users.

Acknowledgements

Written by Erik Schluntz and Barry Zhang. This work draws upon our experiences building agents at Anthropic and the valuable insights shared by our customers, for which we're deeply grateful.

Appendix 1: Agents in practice

Our work with customers has revealed two particularly promising applications for AI agents that demonstrate the practical value of the patterns discussed above. Both applications illustrate how agents add the most value for tasks that require both conversation and action, have clear success criteria, enable feedback loops, and integrate meaningful human oversight.

A. Customer support

Customer support combines familiar chatbot interfaces with enhanced capabilities through tool integration. This is a natural fit for more open-ended agents because:

- Support interactions naturally follow a conversation flow while requiring access to external information and actions;
- Tools can be integrated to pull customer data, order history, and knowledge base articles;
- Actions such as issuing refunds or updating tickets can be handled programmatically; and
- Success can be clearly measured through user-defined resolutions.

Several companies have demonstrated the viability of this approach through usage-based pricing models that charge only for successful resolutions, showing confidence in their agents' effectiveness.

B. Coding agents

The software development space has shown remarkable potential for LLM features, with capabilities evolving from code completion to autonomous problem-solving. Agents are particularly effective because:

- Code solutions are verifiable through automated tests;
- Agents can iterate on solutions using test results as feedback;
- The problem space is well-defined and structured; and

- Output quality can be measured objectively.

In our own implementation, agents can now solve real GitHub issues in the SWE-bench Verified benchmark based on the pull request description alone. However, whereas automated testing helps verify functionality, human review remains crucial for ensuring solutions align with broader system requirements.

Appendix 2: Prompt engineering your tools

No matter which agentic system you're building, tools will likely be an important part of your agent. Tools enable Claude to interact with external services and APIs by specifying their exact structure and definition in our API. When Claude responds, it will include a tool use block in the API response if it plans to invoke a tool. Tool definitions and specifications should be given just as much prompt engineering attention as your overall prompts. In this brief appendix, we describe how to prompt engineer your tools.

There are often several ways to specify the same action. For instance, you can specify a file edit by writing a diff, or by rewriting the entire file. For structured output, you can return code inside markdown or inside JSON. In software engineering, differences like these are cosmetic and can be converted losslessly from one to the other. However, some formats are much more difficult for an LLM to write than others. Writing a diff requires knowing how many lines are changing in the chunk header before the new code is written. Writing code inside JSON (compared to markdown) requires extra escaping of newlines and quotes.

Our suggestions for deciding on tool formats are the following:

- Give the model enough tokens to "think" before it writes itself into a corner.
- Keep the format close to what the model has seen naturally occurring in text on the internet.
- Make sure there's no formatting "overhead" such as having to keep an accurate count of thousands of lines of code, or string-escaping any code it writes.

One rule of thumb is to think about how much effort goes into human-computer interfaces (HCI), and plan to invest just as much effort in creating good *agent*-computer interfaces (ACI). Here are some thoughts on how to do so:

- Put yourself in the model's shoes. Is it obvious how to use this tool, based on the description and parameters, or would you need to think carefully about it? If so, then it's probably also true for the model. A good tool definition often includes example usage, edge cases, input format requirements, and clear boundaries from other tools.
- How can you change parameter names or descriptions to make things more obvious? Think of this as writing a great docstring for a junior developer on your team. This is especially important when using many similar tools.
- Test how the model uses your tools: Run many example inputs in our workbench to see what mistakes

the model makes, and iterate.

- Poka-yoke your tools. Change the arguments so that it is harder to make mistakes.

While building our agent for SWE-bench, we actually spent more time optimizing our tools than the overall prompt. For example, we found that the model would make mistakes with tools using relative filepaths after the agent had moved out of the root directory. To fix this, we changed the tool to always require absolute filepaths—and we found that the model used this method flawlessly.